

Raport z listy 1

Modele regresji i ich zastosowania

Tadeusz Jagniewski, album 277522

2026-03-18

Spis treści

1	Wstęp	1
2	Zadanie 1	2
3	Zadanie 2	3
4	Zadanie 3	4
5	Zadanie 4	5
6	Zadanie 5	5
7	Zadanie 6	6
8	Zadanie 7	7
9	Zadanie 8	8
10	Zadanie 9	12
11	Zadanie 10	13
11.1	Podpunkt (a)	13
11.2	Podpunkt (b)	13
11.3	Podpunkt (c)	14
11.4	Podpunkt (d)	15

1 Wstęp

Wczytujemy dane z pliku *lab 1 i 2.xlsx*.

```
dane <- read_excel("L1.xlsx")
x <- dane$x
y <- dane$y
```

2 Zadanie 1

Wykorzystamy funkcję *wskazniki.statystyczne()*.

```
wskazniki.statystyczne <- function(x){
  podsumowanie <- data.frame(
    Statystyka = c(
      "Minimum",
      "Mediana",
      "Średnia",
      "Pierwszy kwantyl",
      "Trzeci kwantyl",
      "Maksimum",
      "Wariancja",
      "Odchylenie Standardowe"
    ),
    Wartość = c(
      min(x),
      median(x),
      mean(x),
      quantile(x, 0.25),
      quantile(x, 0.75),
      max(x),
      var(x),
      sd(x)
    )
  )
  return(podsumowanie)
}
```

Wyznaczamy szukane wskaźniki statystyczne dla zmiennych x oraz y .

```
x_stat <- wskazniki.statystyczne(x)
y_stat <- wskazniki.statystyczne(y)
```

Wyniki zebrano w tabeli 1 i 2.

	Statystyka	Wartość
1	Minimum	0.02
2	Mediana	4.88
3	Średnia	4.89
4	Pierwszy kwantyl	2.32
5	Trzeci kwantyl	7.51
6	Maksimum	9.98
7	Wariancja	8.37
8	Odchylenie Standardowe	2.89

Tabela 1: Podsumowanie statystyczne kolumny X

	Statystyka	Wartość
1	Minimum	2024.69
2	Mediana	2040.88
3	Średnia	2040.64
4	Pierwszy kwantyl	2032.65
5	Trzeci kwantyl	2048.06
6	Maksimum	2056.66
7	Wariancja	75.98
8	Odchylenie Standardowe	8.72

Tabela 2: Podsumowanie statystyczne kolumny Y

Wnioski: W przypadku obu zmiennych średnia arytmetyczna jest niemal identyczna z medianą.

Zmienna X charakteryzuje się małymi wartościami o stosunkowo dużym rozproszeniu, natomiast zmienna Y przyjmuje duże wartości, które są bardzo stabilne i silnie skupione wokół średniej; obie zmienne mają wysoce symetryczne rozkłady.


3 Zadanie 2

Próbkowy współczynnik korelacji Pearsona wyraża się wzorem

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$$

i jest zaimplementowany w funkcji *cor*. Próbkowa wartość współczynnika korelacji Pearsona wynosi zatem 0.9946.

Wykres rozrzutu zmiennych x, y jest przedstawiony na rysunku 1



Rysunek 1: Wykres rozrzutu dla zmiennych x oraz y

Wnioski: Wykres rozrzutu sugeruje liniową zależność i współczynnik pearsona sugeruje podobnie, bo jest zbliżony do 1.

4 Zadanie 3

Estymatory MNK (metody najmniejszych kwadratów, ang. LSE=Least Squares Errors) parametrów β_0 oraz β_1 są dane wzorami

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Wartości estymowanych współczynników możemy wyznaczyć przy użyciu funkcji *estymatory()*.

```
estymatory <- function(x, y) {
  beta1 <- sum((x - mean(x)) * (y - mean(y))) / sum((x - mean(x))^2)

  beta0 <- mean(y) - beta1 * mean(x)

  return(c(beta0, beta1))
}
```

```
wyniki <- estymatory(x, y)

beta0 <- wyniki[1]
beta1 <- wyniki[2]
```

Otrzymujemy oszacowania $\hat{\beta}_0 = 2025.9754064$ oraz $\hat{\beta}_1 = 2.9966636$.

5 Zadanie 4

Estymator σ^2 wyraża się wzorem

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

gdzie $\hat{y}_i$ oznacza prognozowaną przez model wartość zmiennej objaśnianej y_i , odpowiadającą wartości x_i , zmiennej objaśniającej x . Zatem

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i.$$

Do wyznaczenia estymatora parametru σ^2 użyjemy odpowiednio funkcji *prognoza()* oraz *sigma2()*.

```
prognoza <- function(x, beta0, beta1){
  y <- beta0 + beta1*x
  return(y)
}

sigma2 <- function(y,y.est){
  s <- sum((y - y.est)^2) / (length(y)-2)
  return(s)
}
```

```
# Tworzymy [y.est] oraz [sigma2.est]
y.est <- prognoza(x,beta0,beta1)
sigma2.est <- sigma2(y,y.est)
```

Otrzymujemy zatem, że $\hat{\sigma}^2 = 0.8258558$.

6 Zadanie 5

Na poziomie istotności $\alpha = 0.05$ weryfikujemy następującą hipotezę:

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0$$

W tym celu definiujemy statystykę $SE_{\hat{\beta}_1}^2$ wzorem

$$SE_{\beta_1}^2 = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Jeśli hipoteza H_0 jest prawdziwa, to statystyka testowa ma postać

$$T = \frac{\hat{\beta}_1}{SE_{\beta_1}}$$

a jej rozkład to rozkład t-Studenta z $n - 2$ stopniami swobody tj. t_{n-2} . Skoro test odrzuca hipotezę zerową H_0 , gdy $|T| \geq t_{\alpha/2, n-2}$, to p-value (p-wartość) wyznaczamy ze wzoru

$$\text{p-value} = 2 \cdot \mathbb{P}(|T| \geq |T_{obs}|) = 2 \cdot (1 - F_{n-2}(|T_{obs}|))$$

gdzie $F_{n-2}(T_{obs})$ jest dystrybucją rozkładu t_{n-2} dla zaobserwonej wartości T_{obs} statystyki T .

Do weryfikacji rozważanej hipotezy wykorzystamy funkcję *test.istotności()*.

```
test.istotnosci<-function(sigma2.est, x, beta1, alpha){
  SE2.beta1 <- sigma2.est / sum((x-mean(x))^2)
  T.stat = beta1 / sqrt(SE2.beta1)
  t <- qt(1 - (alpha/2), length(x) - 2)
  p.value <- 2*pt(abs(T.stat),length(x)-2, lower.tail = FALSE)
  y <- matrix(c(T.stat, t, p.value), ncol=3, nrow=1)
  colnames(y)<-c("Statystyka testowa", "Kwantyl rzędu 1-alpha/2", "p-value")
  return(y)
}
```

Tutaj p – value wynosi $1.3339279 \times 10^{-196}$

Wnioski: Odrzucamy Hipotezę zerową, bo p-wartość jest mniejsza od poziomu istotności 0.05, więc wartość β_1 nie będzie równa zero

Dokładne wyniki przeprowadzonego testu istotności współczynnika β_1 są podane w tabeli 3

Statystyka testowa	Kwantyl rzędu 1-alpha/2	p-value
134.57	1.97	0.00

Tabela 3: Wyniki testu istotności współczynników modelu regresji

7 Zadanie 6

Do wyznaczenia realizacji przedziału ufności $[T_L(X), T_U(X)]$ na poziomie ufności $1 - \alpha$ dla parametru β_1 , przy założeniu, że $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ i.i.d o rozkładzie $\mathcal{N}(0, \sigma^2)$ wykorzystamy wzory

$$T_L(X) = \hat{\beta}_1 - t_{\alpha/2, n-2} \cdot SE_{\beta_1}, \quad T_U(X) = \hat{\beta}_1 + t_{\alpha/2, n-2} \cdot SE_{\beta_1}$$

i zaimplementujemy je w funkcji *przedzial.ufnosci.beta()*.

```
przedzial.ufnosci.beta <- function(sigma2.est,x,beta1,alpha){
  SE2.beta1 <- sigma2.est / sum((x-mean(x))^2)
  t1 <- qt(1-alpha/2, length(x)-2)
  t.lower <- beta1 - t1*sqrt(SE2.beta1)
  t.upper <- beta1 + t1*sqrt(SE2.beta1)
  y<-matrix(c(t.lower,t.upper),ncol=2,nrow=1)
  colnames(y)<-c("T-lower","T-upper")
  return(y)
}

t.beta1 <- przedzial.ufnosci.beta(sigma2.est,x,beta1,0.01)
```

Realizacja przedziału ufności parametru β_1 na poziomie ufności $1-\alpha = 0.99$ wynosi [2.9387465, 3.0545808]

8 Zadanie 7

Do wyznaczenia realizacji przedziału ufności $[T_L(X), T_U(X)]$ na poziomie ufności $1-\alpha$ dla wartości $Y(x_0)$ prognozowanej przez model, przy założeniu, że $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ *i.i.d* o rozkładzie $\mathcal{N}(0, \sigma^2)$, wykorzystamy wzory

$$T_L(X) = Y(\hat{x}_0) - t_{\alpha/2, n-2} \cdot SE_{Y(\hat{x}_0)-Y(x_0)}, \quad T_U(X) = Y(\hat{x}_0) + t_{\alpha/2, n-2} \cdot SE_{Y(\hat{x}_0)-Y(x_0)},$$

gdzie

$$Y(\hat{x}_0) = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_0$$

oraz

$$SE_{Y(\hat{x}_0)-Y(x_0)}^2 = \hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right).$$

i zaimplementujemy je w funkcji *przedzial.ufnosci.prognoza()*, przy czym przyjmujemy, że $x_0 = 1$ a poziom ufności to $1-\alpha = 0.99$.

```
przedzial.ufnosci.prognoza<-function(sigma2.est, x, alpha, x_0, y_0){
  SE2.y <- sigma2.est * (1 + 1/length(x) + ((x_0 - mean(x))^2)/sum((x-mean(x))^2))
  t2 <- qt(1-alpha/2, length(x)-2)
  y.pred <- prognoza(x_0, beta0, beta1)
  t.lower <- y.pred - t2*sqrt(SE2.y)
  t.upper <- y.pred + t2*sqrt(SE2.y)
  y <- matrix(c(t.lower,t.upper),ncol=2,nrow=1)
```

```
colnames(y)<-c("T-lower", "T-upper")
return(y)
}
```

```
x_0 <- 1
```

```
y_0 <- prognoza(x_0, beta0, beta1)
```

```
t.prognoza <- przedział.ufności.prognoza(sigma2.est, x, 0.01, x_0, y_0)
```


Realizacja przedziału ufności dla wartości prognozowanej $Y(\hat{x}_0) = 2028.97207$ na poziomie ufności $1 - \alpha = 0.99$ wynosi $[2026.5918669, 2031.3522731]$

9 Zadanie 8

Wyznaczmy rezydua dla naszego modelu w oparciu o wartości zmiennych x i y za pomocą funkcji *rezydum()*.


```
rezydum<-function(y,y_0){
  e <- y - y_0
  return(e)
}
```

Histogram rezydów jest przedstawiony na rysunku 2.




Rysunek 2: Histogram rezyduów

Wykres kwantylowy rezyduów jest przedstawiony na rysunku 3.




Rysunek 3: Wykres kwantylowy rezyduów

Wykres rozrzutu rezyduów względem estymowanych wartości jest przedstawiony na rysunku 4.



Rysunek 4: Wykres rozrzutu rezyduów względem prognoz

Wykres rozrzutu rezyduów względem wartości zmiennej x jest przedstawiony na rysunku 5.



Rysunek 5: Wykres rozrzutu rezyduów względem wartości zmiennej x

Wnioski:

Histogram rezyduów przypomina swoim kształtem krzywą gęstości rozkładu normalnego. Co ważniejsze, punkty na wykresie kwantylowym układają się niemal idealnie wzdłuż wyznaczonej prostej. Świadczy to o tym, że założenie o normalności rozkładu błędów (szumów) jest spełnione.

Na obu wykresach rozrzutu rezyduów – zarówno względem wartości prognozowanych, jak i zmiennej objaśniającej X – punkty tworzą całkowicie losową “chmurę” skupioną wokół osi równej zero.

Na podstawie powyższych rysunków nie ma żadnych podstaw do stwierdzenia, że którekolwiek z założeń klasycznego modelu regresji liniowej nie jest spełnione.

10 Zadanie 9

Modyfikujemy ostatnią wartość zmiennej y i wyznaczamy nowe estymatory parametrów β_0 oraz β_1 .

```
# zmieniamy [y] na [y.new]

y.new <- y
```

```

y.new[200] <- y.new[200] * 10

# nowe estymatory [beta0.new] oraz [beta1.new]

wyniki.new <- estymatory(x, y.new)

beta0.new <- wyniki.new[1]
beta1.new <- wyniki.new[2]

```

Wnioski: Po przemnożeniu ostatniej wartości przez 10 wartości estymatorów β_0 oraz β_1 kompletnie się zmieniają i tracą sens. $\hat{\beta}_0$ wynosi 2171.8248487 (wcześniej 2025.9754064) z kolei $\hat{\beta}_1$ wynosi -8.0621601 (wcześniej 2.9966636).

Więc jest to zdecydowanie wartość odstająca, a zarazem wartość wpływowa, ponieważ znacząco wpływa na estymatory MNK.

11 Zadanie 10

Generujemy próby $(x_1, x_2, \dots, x_n)$ z rozkładu $\mathcal{U}(-2, 2)$ oraz $(\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n)$ z rozkładu $\mathcal{N}(0, \sigma^2)$.

$\beta_0 = 0$, $\beta_1 = 2$, $\sigma = 0.1$

```

x.10 <- runif(200, -2, 2)
beta.0 <- 1
beta.1 <- 2

```

11.1 Podpunkt (a)

Tworzymy funkcję *generuj_y* do generowania próby $(y_1, y_2, \dots, y_n)$.


```

generuj_y <- function(beta.0, beta.1, x.10, sigma){
  eps <- rnorm(200, 0, sigma)
  y.10 <- beta.0 + beta.1*x.10 + eps
  return(y.10)
}
y.10 <- generuj_y(beta.0, beta.1, x.10, 0.1)

```

11.2 Podpunkt (b)

Wykres rozproszenia jest pokazany na rysunku 6



Rysunek 6: Wykres rozproszenia próby

Wnioski: Widać ewidentny charakter liniowy i równomierne rozłożenie próby x.

11.3 Podpunkt (c)

Wyznaczamy szukane estymatory.

```
est.10 <- estymatory(x.10,y.10)
beta.0.est <- est.10[1]
beta.1.est <- est.10[2]
y.est.1 <- beta.0.est + beta.1.est * x.10
```

Wyniki są podane w tabeli ??

	Wartość dokładna	Oszacowanie
beta.0	1.0000	1.0011
beta.1	2.0000	2.0025

Tabela 4: Współczynniki modelu regresji z zadania 10.

Wnioski: Estymatory podają bardzo zbliżone wartości do rzeczywistych wartości β_0 oraz β_1 .

11.4 Podpunkt (d)

Tworzymy funkcję $R2()$ do wyznaczania współczynnika determinacji, który wyznaczam ze wzoru:

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

```
R2<-function(y,y.est){  
  return(sum((y.est - mean(y))^2) / sum((y - mean(y))^2))  
}
```

Powtarzamy obliczenia dla $\sigma = 0.5$ oraz $\sigma = 1$.

```
y.5 <- generuj_y(beta.0, beta.1, x.10, 0.5)  
est.5 <- estymatory(x.10, y.5)  
beta.0.est.5 <- est.5[1]  
beta.1.est.5 <- est.5[2]  
y.est.5 <- beta.0.est.5 + beta.1.est.5 * x.10  
  
y.1 <- generuj_y(beta.0, beta.1, x.10, 1)  
est.1 <- estymatory(x.10, y.1)  
beta.0.est.1 <- est.1[1]  
beta.1.est.1 <- est.1[2]  
y.est.11 <- beta.0.est.1 + beta.1.est.1 * x.10  
  
R2.s.0.1 <- R2(y.10, y.est.1)  
R2.s.0.5 <- R2(y.5, y.est.5)  
R2.s.1.0 <- R2(y.1, y.est.11)
```

Wyniki estymacji bet podane są w tabeli 5

	sigma=0.1	sigma=0.5	sigma=1
beta_0	1.0011	1.0433	1.1207
beta_1	2.0025	2.0136	1.9075

Tabela 5: Estymatory parametrów beta dla różnych wartości sigma

Wyniki R^2 podane są w tabeli 6

	sigma=0.1	sigma=0.5	sigma=1
1	0.9983	0.9558	0.8467

Tabela 6: Współczynnik determinacji dla różnych sigma

Wnioski:

Z danych w tabeli jednoznacznie wynika, że wraz ze wzrostem odchylenia standardowego (σ), maleje wartość współczynnika determinacji (R^2). Dla $\sigma = 0.1$ model regresji wyjaśnia niemal całą zmienność zmiennej Y (około 99.83%). Gdy zakłócenia rosną ($\sigma = 1$), dopasowanie zauważalnie spada, a model jest w stanie wyjaśnić już tylko 84.67% zmienności. Potwierdza to, że im większa wariancja błędów w danych, tym słabiej model opisuje badane zjawisko, co bezpośrednio przekłada się na mniejszą precyzję wyznaczanych estymatorów.