

Jagniewski3

Modele regresji i ich zastosowania

Tadeusz Jagniewski, album 277522

2026-03-25

Spis treści

1	Wstęp	2
2	Zadanie 1	2
2.1	Podpunkt (a)	2
2.2	Podpunkt (b)	2
2.3	Podpunkt (c)	3
3	Zadanie 2	3
3.1	Podpunkt (a)	4
3.2	Podpunkt (b)	4
4	Zadanie 3	4
4.1	Podpunkt (a)	4
4.2	Podpunkt (b)	5
4.3	Podpunkt (c)	7
5	Zadanie 4	8
5.1	Podpunkt (a)	8
5.2	Podpunkt (b)	8
6	Zadanie 5	9
6.1	Podpunkt (a)	9
6.2	Podpunkt (c)	10
6.3	Podpunkt (b)	12
7	Zadanie 6	13
7.1	Podpunkt (a)	13
7.2	Podpunkt (b)	14
7.3	Podpunkt (c)	14


1 Wstęp

Wczytujemy dane z pliku *regresja wielokrotna 2026.xlsx*.

```
library(openxlsx)
dane <- read.xlsx("regresja wielokrotna 2026.xlsx")
dane.2 <- dane
```

2 Zadanie 1

```
pairs(dane,
      main = "Macierz wykresów rozrzutu",
      pch = 1,
      col = "blue",
      cex = 0.1)
```



2.1 Podpunkt (a)

Y potencjalnie istotna korelacja z x6, x9, mniejsza z x2, x8, x10

2.2 Podpunkt (b)

Potencjalna korelacja x2 z x8 i z x10, x6 z x9, x8 z x10, Y wykazuje spore szanse na korelację z kilkoma zmiennymi

2.3 Podpunkt (c)

Są obserwacje odstające, prawie na każdym wykresie Y z różnymi X pojawiają się obserwacje, które są oddalone od reszty obserwacji i są widoczne nawet na bardzo małym rysunku.

3 Zadanie 2

Próbkowy współczynnik korelacji Pearsona wyraża się wzorem

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$$


i jest zaimplementowany w funkcji `cor()`.

```
library(corrplot)

n_zmiennych <- ncol(dane)
macierz_korelacji <- matrix(0, nrow = n_zmiennych, ncol = n_zmiennych)
rownames(macierz_korelacji) <- colnames(dane)
colnames(macierz_korelacji) <- colnames(dane)

for(i in 1:n_zmiennych) {
  for(j in 1:n_zmiennych) {
    macierz_korelacji[i, j] <- cor(dane[[i]], dane[[j]])
  }
}

corrplot(macierz_korelacji,
  method = "color",
  type = "upper",
  addCoef.col = "black",
  tl.col = "black",
  tl.srt = 45,
  number.cex = 0.7,
  col = colorRampPalette(c("blue", "white", "red"))(200))
```



3.1 Podpunkt (a)

Względem Y istotne (moduł korelacji większy niż 0.5) są zmienne X2, X6, X8, X9, X10

3.2 Podpunkt (b)

Korelacja między X2 a X8 i X10 (też między X8 i X10 korelacja), oraz X6 i X9

4 Zadanie 3

Konstruujemy model regresji liniowej opisujący zależność pomiędzy zmienną objaśnianą Y a zmiennymi objaśniającymi $X_1, X_2, \dots, X_{10}$.

W tym celu wyznaczymy estymator

$$\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_{10})$$

parametrów

$$\beta = (\beta_1, \beta_2, \dots, \beta_{10})$$

tego modelu regresji liniowej.

4.1 Podpunkt (a)

Posłużymy się metodą najmniejszych kwadratów. Wówczas mamy

$$\hat{\beta} = \mathbb{X}(\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T Y$$

Wzór ten jest zaimplementowany w funkcji *estymatory.beta()*.

```
estymatory.beta <- function(x, y) {
  wektor.1 <- rep(1, length(y))
  x <- cbind(wektor.1, as.matrix(x))
  beta <- solve(t(x) %*% x) %*% t(x) %*% y

  return(beta)
}
```

```
library(kableExtra)
X <- as.matrix(dane[, names(dane) != "Y"])
Y <- as.matrix(dane$Y)

beta <- estymatory.beta(X, Y)
betet <- data.frame(beta)
kable(betet)
```

	beta
wektor.1	-0.3663314
X1	1.3122296
X2	2.4817921
X3	3.6439204
X4	4.4129815
X5	0.4826617
X6	5.1026333
X7	1.0512518
X8	0.8373855
X9	-0.4389655
X10	-0.1538112

4.2 Podpunkt (b)

Funkcja *prognoza()* implementuje wzór na predykcje:

$$\hat{Y} = \mathbb{X}\hat{\beta}.$$

```
prognoza <- function(x, beta) {
  wektor.1 <- rep(1, length(x[, 1]))
  x <- cbind(wektor.1, as.matrix(x))
```

```

    prognozowane_y <- x %*% beta

    return(prognozowane_y)
}

Y.hat <- prognoza(X, beta)

```

Do zweryfikowania hipotezy zerowej

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-2} = \beta_{p-1} = 0,$$

przy alternatywie

$$H_1 : \beta_1 \neq 0 \quad \vee \quad \beta_2 \neq 0 \quad \vee \quad \dots \quad \vee \quad \beta_{p-2} \neq 0 \quad \vee \quad \beta_{p-1} \neq 0,$$

wykorzystamy statystykę testową F określoną następująco:

$$F = \frac{SSR}{SSE} \cdot \frac{n-p}{p-1},$$

gdzie

- n jest długością próby,
- p jest liczbą zmiennych objaśniających powiększoną o jeden (zmienną $X_0 = 1$),
- $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$,
- $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

Hipotezę H_0 odrzucamy, gdy p-value określona jako

$$p - value = \mathbb{P}_{H_0}(F \geq F_{obs}) = 1 - F_{p-1, n-p}(F_{obs})$$

spełnia

$$p - value \leq \alpha$$

dla ustalonego wcześniej poziomu istotności α , przy czym $F_{m_1, m_2}(t)$ jest dystrybuantą rozkładu F Snedecora, z m_1, m_2 stopniami swobody, ewaluowaną w punkcie t .

Opisany test został zaimplementowany w funkcji $test.F()$.

```
test.F<-function(x,y,y.hat){

  p <- length(x[1,]) + 1
  n <- length(x[, 1])

  SSR <- sum((y.hat - mean(y))^2)
  SSE <- sum((y - y.hat)^2)

  F.stat <- (SSR / SSE) * ((n - p) / (p - 1))

  p.value <- 1 - pf(F.stat, df1 = p - 1, df2 = n - p)

  return(p.value)}

p.value <- test.F(X, Y, Y.hat)
```

P-value wynosi 0, więc odrzucamy hipotezę zerową, więc przynajmniej jedna beta jest niezerowa więc model regresji ma sens.

4.3 Podpunkt (c)

Wartości współczynnika determinacji obliczamy ze wzoru

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

zaimplementowanego w funkcji *współczynnik.determinacji()*.

```
współczynnik.determinacji<-function(y,y.est){
  return(sum((y.est-mean(y))^2)/sum((y-mean(y))^2))
}

# współczynnik determinacji [R] na podstawie [Y] oraz [Y.hat]
R <- współczynnik.determinacji(Y, Y.hat)
```

Współczynnik wychodzi 0.999386, współczynnik jest wysoki więc model jest dobrze dopasowany

Wartości skorygowanego współczynnika determinacji obliczamy ze wzoru

$$Adj R^2 = 1 - \frac{(1 - R^2) \cdot (n - 1)}{n - p - 1}$$

zaimplementowanego w funkcji *skorygowany.współczynnik.determinacji()*.

```

skorygowany.współczynnik.determinacji<-function(R,n,p){
  return(1 - ((1-R)*(n-1))/(n-p-1))
}

# skorygowany współczynnik determinacji [R.adj]
# na podstawie [R], length(Y), length(beta)
R.adj <- skorygowany.współczynnik.determinacji(R, length(Y),length(beta))

```

AdjR wynosi 0.9993501 więc wnioski są analogiczne jak w poprzednim R

5 Zadanie 4

5.1 Podpunkt (a)

Współczynnik podbicia wariancji VIF_j określamy wzorem

$$VIF_j = \frac{1}{1 - R_j^2},$$

gdzie R_j^2 jest współczynnikiem determinacji w modelu regresji liniowej, w którym

- zmienna X_j jest zmienną objaśnianą,
- zmienne $X_0, X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_{p-2}, X_{p-1}$ są zmiennymi objaśniającymi

```

VIF<-function(y,y.est){
  return(1/(1 - współczynnik.determinacji(y,y.est)))
}

```

5.2 Podpunkt (b)

W danym modelu odrzucamy zmienną X_j o największej wartości VIF_j , jeżeli przekracza ona wartość 10.

Wartości współczynnika VIF_j można obliczyć za pomocą funkcji $VIF()$.

```

testuj<-1:10

while(T){
  Vif.value<-numeric(10)

  for (i in 1:10){
    if (testuj[i]!=0){
      indeksy<-setdiff(which(testuj>0),i)
      b<-estymatory.beta(X[,indeksy],X[,i])
      Y.h<-proгноza(X[,indeksy],b)
    }
  }
}

```



```

    Vif.value[i]<-VIF(X[,i],Y.h)}
  }
  if (max(Vif.value)<=10){
    break}

testuj[which(Vif.value==max(Vif.value))]<-0
}

new.X.1<-cbind(rep(1,length(X[,1])),X[,which(testuj>0)])
new.X<-X[,which(testuj>0)]
new.xt <- data.frame(new.X)
kable(head(new.xt), caption = "Nowe X po usunięciu niepotrzebnych")

```

Tabela 2: Nowe X po usunięciu niepotrzebnych

	X1	X2	X3	X4	X5	X6	X7
	0.6597140	-5.6092402	0.2172855	4.791584	0.1260555	14.091260	-2.3680662
	1.1404091	0.6059029	2.1326459	5.601846	-1.3332214	6.478854	-3.4207380
	-0.0412048	3.0708305	2.5504015	2.329135	-5.5332851	7.574904	0.9948102
	0.2861375	3.8183739	2.3384225	4.068552	-3.3686469	8.308654	-5.0401507
	0.9746645	-8.7583370	2.7823743	5.655357	-3.3128995	2.685610	-5.6529542
	-1.2484503	2.6710361	1.0754529	5.839894	-2.1262674	7.998015	-2.3492392

Więc zostały usunięte X8, X9 i X10 zgodnie z przypuszczeniami na początku analizy.

6 Zadanie 5

6.1 Podpunkt (a)

Określamy macierz $\mathbb{H}$ następująco:

$$\mathbb{H} := \mathbb{X}(\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T$$

Wówczas wartość $x_j = (x_{1,j}, x_{2,j}, \dots, x_{p-1,j})$ jest wpływowa, gdy

$$h_{j,j} > \frac{3p}{n}.$$

Implementujemy wzór na macierz $\mathbb{H}$.

```

macierz.H <- new.X.1 %*% solve(t(new.X.1) %*% new.X.1) %*% t(new.X.1)

diagonal <- diag(macierz.H)


```

```
p <- 7
u.1 <- which(diagonal > (3 * p) / length(Y))
```

Tworzymy wykres zależności wartości wpływów od numeru obserwacji, z naniesionym progiem odcięcia równym $3p/n$.

```
n <- 200
plot(x=1:n, y=diagonal[1:n],
     xlab="indeks",
     ylab="wp.yw",
     main="Wartości wpływów dla kolejnych obserwacji")
text(x=u.1, y=diagonal[u.1], labels=u.1, cex=0.7, pos=2)
abline(h = 3*p/n, col="red")
```

Wartości wp.ywów dla kolejnych obserwacji



Obserwacje wpływowe 149, 195

6.2 Podpunkt (c)

Studentyzowane rezyduum r_i jest zdefiniowane jako

$$r_i = \frac{y_i - \hat{y}_i}{\hat{\sigma} \sqrt{1 - h_{i,i}}},$$

przy czym

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}$$

i ten estymator jest zaimplementowany w funkcji *sigma.est()*.

Wówczas wartość $x_j = (x_{1,j}, x_{2,j}, \dots, x_{p-1,j})$ jest wpływowa, gdy

$$|r_i| > 2.$$

Estymator $\hat{\sigma}^2$ implementujemy w funkcji *sigma.est()*.

```
sigma.est<-function(y,y.hat,beta){
  return(sum((y-y.hat)^2)/(length(y)-length(beta)))}
```

Wyznaczamy studentyzowane rezydua.

```
# oszacowania beta na podstawie [new.X] oraz [Y]
new.beta <- estymatory.beta(new.X, Y)

# prognozy na podstawie [new.X] oraz [new.beta]
new.Y.hat <- prognoza(new.X, new.beta)

# oszacowania sigma na podstawie [Y], [new.Y.hat] oraz [new.beta]
new.sigma <- sigma.est(Y, new.Y.hat, new.beta)


# studentyzowane rezydua na podstawie [Y], [new.Y.hat], [new.sigma], [diagonal]
r <- (Y- new.Y.hat) / (new.sigma * sqrt(1 - diagonal))

# numery obserwacji wpływowych wg studentyzowanych rezyduów
u.2 <- which(abs(r)>2)
```

Tworzymy wykres zależności wartości studentyzowanych rezyduuów od numeru obserwacji, z naniesionymi progami odcięcia równymi 2 oraz -2.

```
n <- 200
plot(x=1:n, y=r[1:n],
     xlab="indeks",
     ylab="wpływ",
     main="Wartości studentyzowanych rezyduów dla kolejnych obserwacji")
text(x=u.2, y=r[u.2], labels=u.2, cex=0.7, pos=2)
abline(h = 2, col="red")
abline(h = -2, col="red")
```

artykuści studentyzowanych rezyduów dla kolejnych obser



Obserwacje wpływowe 5, 31, 41, 43, 51, 53, 104, 143, 154, 167

6.3 Podpunkt (b)

Określamy odległość Cooka D_i następująco:

$$D_i = r_i^2 \cdot \frac{h_{i,i}}{1 - h_{i,i}} \cdot \frac{1}{p},$$

Wówczas wartość $x_j = (x_{1,j}, x_{2,j}, \dots, x_{p-1,j})$ jest wpływowa, gdy

$$D_i \geq \frac{4}{n - p}.$$

Wyznamy odległości Cooke'a dla kolejnych obserwacji.

```
# odległości Cooke'a na podstawie [r], [diagonal], [p]
D <- r^2 * (diagonal/(1-diagonal) * (1/p))

# numery obserwacji wpływowych wg odległości Cooke'a dla n=length(Y)
u.3 <- which(D >= 4/(length(Y) - p))
```

Tworzymy wykres zależności wartości odległości Cooke'a od numeru obserwacji, z naniesionym progiem odcięcia równym $4/(n - p)$.


```
n <- 200
plot(x=1:n, y=D[1:n],
     xlab="indeks",
     ylab="wpływ",
```

```

main="Wartości odległości Cooke'a dla kolejnych obserwacji")
text(x=u.3, y=D[u.3], labels=u.3, cex=0.7, pos=2)
abline(h = 4 / (n-p), col="red")

```

Wartości odleg.o.ci Cooke'a dla kolejnych obserwac



Wpływowe obserwacje 5, 17, 31, 41, 43, 51, 71, 96, 104, 129, 147, 154, 167, 195

7 Zadanie 6

7.1 Podpunkt (a)

```

# Z macierzy [new.X] odrzucamy wiersze o numerach [u.1], [u.2], [u.3]
new.X.2 <- new.X[-c(u.1, u.2, u.3), ]

# Z macierzy [Y] odrzucamy wiersze o numerach [u.1], [u.2], [u.3]
new.Y.2 <- Y[-c(u.1, u.2, u.3), ]

# oszacowania beta na podstawie [new.X.2] oraz [new.Y.2]
new.beta.2 <- estymatory.beta(new.X.2, new.Y.2)

beta2t <- data.frame((new.beta.2))
kable(beta2t)

```

	X.new.beta.2.
wektor.1	0.0810122
X1	2.0145877

	X.new.beta.2.
X2	4.0044840
X3	6.2000179
X4	3.9922212
X5	0.0497413
X6	5.9783250
X7	1.0506423

7.2 Podpunkt (b)

```
# nowe prognozy na podstawie [new.X.2] oraz [new.beta.2]
new.Y.hat.2 <- prognoza(new.X.2, new.beta.2)

# nowa p-wartość na podstawie [new.X.2], [new.Y.2], [new.Y.hat.2]
p.value.nowe <- test.F(new.X.2, new.Y.2, new.Y.hat.2)
```

P-wartość wychodzi 0, więc odrzucamy hipotezę zerową i model regresji jest sensowny bo przynajmniej jedno beta nie jest równe 0.

7.3 Podpunkt (c)

```
# nowe R^2 na podstawie [new.Y.2] oraz [new.Y.hat.2]
R.nowe <- współczynnik.determinacji(new.Y.2, new.Y.hat.2)

# nowe skorygowane R^2 na podstawie [R], [length(new.Y.2)], [length(beta)]
R.adj.nowe <- skorygowany.współczynnik.determinacji(R.nowe, length(new.Y.2), length(new
```

współczynniki wynoszą odpowiednio $R=0.9995028$, $AdjR=0.9994799$, więc są wysokie więc model jest dobrze dopasowany.