

Raport z listy 6

Modele regresji i ich zastosowania

Tadeusz Jagniewski, album 277522

2026-04-15

Spis treści

1	Wstęp	1
2	Zadanie 1	2
2.1	Podpunkt (a)	2
2.2	Podpunkt (b)	2
2.3	Podpunkt (c)	4
2.4	Podpunkt (d)	5
2.5	Podpunkt (e)	7
3	Zadanie 2	7
3.1	Podpunkt (a)	7
3.2	Podpunkt (b)	8
3.3	Podpunkt (c)	9

1 Wstęp

Wczytujemy dane z pliku *regresja wielokrotna 2026.xlsx*.

```
dane <- read.csv("dane.csv")
```

```
# tworzymy [X] [Y] jako odpowiednie macierze z [dane]
X <- as.matrix(dane[, 1:7])
Y <- as.matrix(dane[, 8, drop = FALSE])
```

2 Zadanie 1

2.1 Podpunkt (a)

Wykorzystamy funkcję `step()`. Na początek utworzymy model początkowy (tylko ze stałą) oraz model pełny (ze wszystkimi predyktorami).

```
# model początkowy zawierający tylko stałą
model.initial <- lm(Y ~ 1, dane)

# model pełny ze wszystkimi predyktorami X1, X2, X3, X4, X5, X6, X7
model.full <- lm(Y ~ ., dane)
```

Zacznijmy od modelu regresji krokowej typu “forward”.

```
model.forward <- step(object = model.initial, direction = "forward", scope = list(lower
```

Wniosek: Zostały dodane wszystkie zmienne oprócz X5, a zmienne były dodwane w kolejności: X6, X2, X4, X3, X7, X1

Następnie sprawdzimy model regresji krokowej typu “backward”.

```
model.backward <- step(model.full, direction = "backward")
```

Wniosek: Został usunięty predyktor X5, ponieważ usunięci innych sprawia, że kryterium akaike rośnie.

Na koniec zobaczymy jeszcze jak wygląda model regresji krokowej typu “both”.

```
model.both <- step(model.full, direction = "both")
```

Wniosek: Tutaj również usunięty został predyktor X5.

Zatem wybieramy model backward

```
# model M
M <- model.backward

# [X.M] jako wszystkie predyktory [X] ale bez ...
X.M <- X[, -5]
```

2.2 Podpunkt (b)

Do zweryfikowania hipotezy zerowej

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-2} = \beta_{p-1} = 0,$$

przy alternatywie

$$H_1 : \beta_1 \neq 0 \vee \beta_2 \neq 0 \vee \dots \vee \beta_{p-2} \neq 0 \vee \beta_{p-1} \neq 0,$$

wykorzystamy statystykę testową F określoną następująco:

$$F = \frac{SSR}{SSE} \cdot \frac{n-p}{p-1},$$

gdzie

- n jest długością próby,
- p jest liczbą zmiennych objaśniających powiększoną o jeden (zmienną $X_0 = 1$),
- $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$,
- $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$

Hipotezę H_0 odrzucamy, gdy p-wartość określona jako

$$p - value = \mathbb{P}_{H_0}(F \geq F_{obs}) = 1 - F_{p-1, n-p}(F_{obs})$$

spełnia

$$p - value \leq \alpha$$

dla ustalonego wcześniej poziomu istotności α , przy czym $F_{m_1, m_2}(t)$ jest dystrybuantą rozkładu F Snedecora, z m_1, m_2 stopniami swobody, ewaluowaną w punkcie t .

Opisany test został zaimplementowany w funkcji `test.F()`.

```
test.F<-function(x,y,y.hat){  
  
  # liczba zmiennych plus 1 (wyraz wolny w modelu regresji)  
  p<-length(x[,1])+1  
  
  # liczba obserwacji  
  n<-length(x[,1])  
  
  # SSR oraz SSE zgodnie ze wzorami  
  SSR<-sum((y.hat-mean(y))^2)  
  SSE<-sum((y-y.hat)^2)  
  
  # wartość statystyki testowej  
  F.stat<-SSR/(p-1)/SSE*(n-p)  
  
  # p-wartość testu  
  p.value<-pf(F.stat,df1=p-1,df2=n-p,lower.tail=FALSE)  
  
  # którą zwracamy  
  return(p.value)}
```

```
# prognozy dla modelu M
Y.hat <- M$fitted.values

# wyznaczamy p-wartość w teście F na podstawie [X.M], [Y], [Y.hat]
p.value <- test.F(X,Y,Y.hat)
```

Skoro $p\text{-value} = 5.1303086 \times 10^{-289}$ to odrzucamy hipotezę zerową, czyli model regresji liniowej jest uzasadniony, bo przynajmniej jedna ze zmiennych ma liniowy wpływ na Y .

2.3 Podpunkt (c)

Do zweryfikowania hipotezy zerowej

$$H_0^{(i)} : \beta_i = 0,$$

przy alternatywie

$$H_1^{(i)} : \beta_i \neq 0,$$

wykorzystamy statystykę testową F_i określoną następująco:

$$F_i = \frac{\hat{\beta}_i^2}{SE_i^2},$$

gdzie $SE_i^2 = \hat{\sigma}^2 (X^T X)^{-1}_{i,i}$.

Przy założeniu, że $H_0^{(i)}$ jest prawdziwa F_i ma rozkład F Snedecora $F(1, n - p)$ z jednym i $n - p$ stopniami swobody.

Co więcej, statystyka ta ma również rozkład taki sam rozkład jak $[T(n - p)]^2$, czyli kwadrat zmiennej losowej T-studenta z $n - p$ stopniami swobody.

Hipotezę $H_0^{(i)}$ odrzucimy, gdy

$$p\text{-value} = 1 - F_{F(1, n-p)}(F_{i, obs})]$$

spełnia $p\text{-value} \leq \alpha$, gdzie α to ustalony poziom istotności, natomiast $F_{F(m_1, m_2)}(t)$ jest dystrybuantą rozkładu F Snedecora z m_1, m_2 stopniami swobody ewaluowaną w punkcie t .

Ten test został zaimplementowany w funkcji `test.F.single()`.

```
# funkcja jak na liście 4
sigma.est<-function(y,y.hat,beta){
  return(sum((y-y.hat)^2)/(length(y)-length(beta)))}

test.F.single<-function(x,y,y.est,beta){

# wyznaczamy oszacowanie sigma
sigma <- sigma.est(y,y.est,beta)
```

```

# dołączamy, z lewej strony, kolumnę jedynek do x
x <- cbind(rep(1,length(x)),x)

# wyznaczamy SE
SE <- sigma * diag(solve(t(x) %*% x))

# obliczamy wartość statystyki testowej
F.stat <- beta^2 / SE

# wyznaczamy p-wartość
p.value.single <- pf(F.stat, 1, length(x)-length(beta), lower.tail = FALSE)

# i ją zwracamy
return(p.value.single)}

# p-wartość w teście F.single
p.value.single <- test.F.single(X.M, Y, Y.hat, M$coefficients)

```

Zatem wszystkie zmienne mają liniowy wpływ na Y , ponieważ ich p -wartości są bliskie zera (dokładnie wynoszą $3.4754748 \times 10^{-179}$, 0, 0, 0, 0, $1.5192274 \times 10^{-261}$) i w każdym przypadku odrzucamy hipotezę zerową.

2.4 Podpunkt (d)

Przedział ufności $[T_L(X), T_U(x)]$ na poziomie ufności $1 - \alpha$ dla parametrów β_i , przy założeniu, że $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ są i.i.d o rozkładzie $\mathcal{N}(0, \sigma^2)$ wyznaczamy ze wzorów

$$T_L(X) = \hat{\beta}_i - t_{n-p}(1 - \alpha/2) \cdot SE_i, \quad T_U(X) = \hat{\beta}_i + t_{n-p}(1 - \alpha/2) \cdot SE_i,$$

gdzie $t_{n-p}(1 - \alpha/2)$ jest kwantylem rzędu $1 - \alpha/2$ rozkładu $T(n - p)$ t-Studenta z $n - p$ stopniami swobody.

```

przedziały.ufności<-function(x,y,y.est,beta,alpha){

# wyznaczamy [sigma], [x], [SE] jak w funkcji test.F.single()

sigma <- sigma.est(y,y.est,beta)

# dołączamy, z lewej strony, kolumnę jedynek do x
x <- cbind(rep(1,length(x)),x)

# wyznaczamy SE
SE <- sigma * diag(solve(t(x) %*% x))

```

```

# wyznaczamy końce przedziału ufności z podanych wzorów
# i zapisujemy jako macierze nakładając as.matrix()
t.lower <- beta - qt(1 - alpha/2, length(x) - length(beta)) * sqrt(SE)
t.upper <- beta + qt(1 - alpha/2, length(x) - length(beta)) * sqrt(SE)

# łączymy kolumnowo otrzymane macierze początków i końców przedziałów ufności
# za pomocą cbind()
przedziały <- cbind(t.lower,t.upper)

# i je zwracamy
return(przedziały)}

# przedziały ufności dla współczynników w modelu regresji krokowej
# na podstawie [X.M], [Y], [Y.hat], [M$coefficients]
# i na poziomie ufności 0.05
library(knitr)
library(kableExtra)

przedziały<- przedziały.ufności(X.M, Y, Y.hat, M$coefficients, 0.05)
kable(
  round(przedziały, 3),
  caption = "Przedziały ufności dla parametrów modelu",
  format = "latex",
  booktabs = TRUE,
  align = "c"
) %>%
  kable_styling(
    latex_options = c("hold_position", "striped"),
    full_width = FALSE,
    position = "center"
  )

```

Tabela 1: Przedziały ufności dla parametrów modelu

	t.lower	t.upper
(Intercept)	-0.788	0.303
X1	1.908	2.144
X2	3.978	4.028
X3	6.103	6.338
X4	3.938	4.072
X6	5.959	6.012
X7	0.999	1.091

Wnioski: Żaden przedział nie zawiera zera (oprócz intercept), więc wszystkie zmienne mają liniowy wpływ na Y.

2.5 Podpunkt (e)

```
# funkcja jak na liście 4
współczynnik.determinacji<-function(y,y.est){
  return(sum((y.est-mean(y))^2)/sum((y-mean(y))^2))
}

# funkcja jak na liście 4
skorygowany.współczynnik.determinacji<-function(R2,n,p){
  return(1-((1-R2)*(n-1))/(n-p-1))
}

# współczynnik determinacji [R2] na podstawie [Y], [Y.hat]
R2<- współczynnik.determinacji(Y, Y.hat)


# skorygowany współczynnik determinacji [Adj.R2] na podstawie
# [R2], n=length(Y), p=length(M$coefficients)
Adj.R2<- skorygowany.współczynnik.determinacji(R2, length(Y), length(M$coefficients))
```

Obydwa współczynniki są bardzo bliskie jedynce, więc to bardzo dobrze świadczy o modelu, mimo usunięcia X5.

3 Zadanie 2

3.1 Podpunkt (a)

```
# reszty [e] na podstawie [Y] oraz [Y.hat]
e <- Y - Y.hat
```



Rysunek 1: Wykres kwantylowy rezyduów


Kilka wartości odstających występuje, aczkolwiek większa część wykresu sugeruje normalność reszt

3.2 Podpunkt (b)

Wykres rozrzutu rezyduów względem każdej ze zmiennych objaśniających X_i dla $i = 1, 2, 3, 4, 6, 7$ jest przedstawiony na rysunku 2.

```
# zmieniamy siatkę wykresów na ...
par(mfrow=c(2,3))

# tworzymy wykresy rozrzutu reszt względem kolejnych predyktorów
for (i in 1:6) {
  plot(X.M[,i], e, main=paste("Dla zmiennej nr", ifelse(i<5, i, i+1)))
}
```




Rysunek 2: Wykres rozrzutu rezyduów względem wartości zmiennej x

```
# powrót do ustawień domyślnych
par(mfrow=c(1,1))
```

Widzimy chmury losowe punktów, co może również wskazywać na normalność reszt.

3.3 Podpunkt (c)

Wykres rozrzutu rezyduów względem estymowanych wartości jest przedstawiony na rysunku 3.



Rysunek 3: Wykres rozrzutu rezyduów względem prognoz

Również ten wykres wskazuje na normlaność reszt, co stawia model w dobrym świetle.