

Raport z listy 7

Modele regresji i ich zastosowania

Tadeusz Jagniewski, album 277522

2026-04-22

Spis treści

```
library(readxl)
dane = read_excel("lab7.xlsx")

Y <- dane$y
X1 <- dane$X1
X2 <- dane$X2
X3 <- dane$X3
coryx1 <- cor(Y, X1)
coryx2 <- cor(Y, X2)
coryx3 <- cor(Y, X3)

resyx1 <- lm(Y ~ X2 + X3, data = dane)$residuals
resx1 <- lm(X1 ~ X2 + X3, data = dane)$residuals
pcoryx1 <- cor(resyx1, resx1)

resyx2 <- lm(Y ~ X1 + X3, data = dane)$residuals
resx2 <- lm(X2 ~ X1 + X3, data = dane)$residuals
pcoryx2 <- cor(resyx2, resx2)

resyx3 <- lm(Y ~ X1 + X2, data = dane)$residuals
resx3 <- lm(X3 ~ X1 + X2, data = dane)$residuals
pcoryx3 <- cor(resyx3, resx3)

wyniki <- data.frame(
  Zmienna_Objaśniająca = c("X1", "X2", "X3"),
  Korelacja_Zwykła = c(coryx1, coryx2, coryx3),
  Korelacja_Cząstkowa = c(pcoryx1, pcoryx2, pcoryx3)
)
library(knitr)
```

```
kable(wyniki,
      caption = "Porównanie korelacji zwykłej i cząstkowej",
      col.names = c("Zmienna Objaśniająca", "Korelacja Zwykła", "Korelacja Cząstkowa"),
      digits = 4,
      align = "c")
```

Tabela 1: Porównanie korelacji zwykłej i cząstkowej

Zmienna Objaśniająca	Korelacja Zwykła	Korelacja Cząstkowa
X1	0.1996	0.8512
X2	0.0075	-0.8393
X3	0.5015	0.7474

Zmienna X1: Zwykły współczynnik korelacji sugerował bardzo słaby związek (około 0.20), jednak korelacja cząstkowa okazała się bardzo silna (0.85). W rzeczywistości X1 ma silny, pozytywny wpływ na Y.

Zmienna X2: Zwykła korelacja była niemal zerowa (0.0075), co na pierwszy rzut oka sugeruje całkowity brak związku. Dopiero korelacja cząstkowa ujawniła bardzo silną, ujemną zależność (-0.84). Pozostałe zmienne łącznie ukrywały fakt, że X2 silnie wpływa na Y

Zmienna X3: Zwykła korelacja była umiarkowana (0.50), ale po odfiltrowaniu wpływu reszty zmiennych wzrosła do silnego poziomu (0.75).

Porównanie obu miar pokazuje, jak myląca może być zwykła korelacja w modelach z wieloma zmiennymi. Dopiero korelacja cząstkowa pozwoliła odkryć, że wszystkie trzy zmienne (X1, X2 i X3) są w rzeczywistości bardzo istotne i silnie powiązane ze zmienną objaśnianą Y.

```
par(mfrow = c(3, 2), mar = c(4, 4, 2, 1))

plot(dane$X1, dane$Y, pch = 16, col = "blue",
     main = "Wykres rozrzutu (Y, X1)", xlab = "X1", ylab = "Y")


plot(resx1, resyx1, pch = 16, col = "darkgreen",
     main = "Regresja cząstkowa (Y, X1 | X2, X3)",
     xlab = "Reszty dla X1", ylab = "Reszty dla Y")
abline(lm(resyx1 ~ resx1), col = "red", lwd = 2)

plot(dane$X2, dane$Y, pch = 16, col = "blue",
     main = "Wykres rozrzutu (Y, X2)", xlab = "X2", ylab = "Y")

plot(resx2, resyx2, pch = 16, col = "darkgreen",
     main = "Regresja cząstkowa (Y, X2 | X1, X3)",
     xlab = "Reszty dla X2", ylab = "Reszty dla Y")
abline(lm(resyx2 ~ resx2), col = "red", lwd = 2)
```

```
plot(dane$X3, dane$Y, pch = 16, col = "blue",
     main = "Wykres rozrzutu (Y, X3)", xlab = "X3", ylab = "Y")

plot(resx3, resyx3, pch = 16, col = "darkgreen",
     main = "Regresja cząstkowa (Y, X3 | X1, X2)",
     xlab = "Reszty dla X3", ylab = "Reszty dla Y")
abline(lm(resyx3 ~ resx3), col = "red", lwd = 2)
```



```
par(mfrow = c(1, 1))
```

Podczas gdy wykresy rozrzutu przypominają losową chmurę, wykresy regresji cząstkowej wyraźnie układają się wzdłuż linii.